

CARRERA DE INGENIERÍA EN SOFTWARE



Proyecto Integrador — Analítica de Negocios
Nivel 7A

Sistema de predicción del rendimiento de cosechas para decisiones de compra

AgroComercial del Litoral S.A. (caso simulado)

Docente:

Ing. Carlos Manosalvas G.

Integrantes:

Chile Silva Carlos Junior
Figueroa Arteaga Luis Emilio
Menoscal Santana Bryan Steven

Manta — Manabí, Ecuador

INDICE

Resumen Ejecutivo	3
Fase 1. Definición del Negocio y Entendimiento del Problema	4
1.1 Contexto del Negocio	4
1.2 Planteamiento del Problema (Cultura Data-Driven)	4
1.3 Objetivos de Analítica (los 4 pilares)	4
1.4 Fuentes de Datos y Ética Inicial	5
Fase 2. Ingeniería de Datos y Modelado Multidimensional	7
2.1 Modelado Multidimensional (Esquema Estrella)	7
2.2 Pipeline de Integración (ETL)	7
2.3 Cumplimiento Normativo	8
Fase 3. Analítica Descriptiva, Diagnóstica y Visualización	9
3.1 Análisis Exploratorio de Datos (EDA)	9
3.2 Diseño de Indicadores (KPIs)	11
3.3 Dashboard Estratégico y Storytelling	12
Fase 4. Analítica Predictiva y Gobernanza de IA	13
4.1 Modelado Predictivo (Machine Learning)	13
4.2 Ética de la IA y Gobernanza de Datos	15
Conclusiones	17

Resumen Ejecutivo

AgroComercial del Litoral S.A. es una comercializadora que compra cosechas a productores ecuatorianos y las revende a industrias, supermercados y compradores de exportación. Su ganancia depende de acertar cuánto comprar cada temporada. Hoy esa decisión se toma más por intuición que por datos, y eso deja a la empresa expuesta a dos errores caros: comprar de más y perder producto por deterioro, o comprar de menos y quedarse sin qué vender cuando hay demanda. Para atacar ese problema desarrollamos una solución analítica que va desde la preparación de los datos hasta un modelo predictivo funcional y un dashboard de apoyo a la decisión, y que estima el rendimiento esperado de los cultivos (ton/ha) para traducirlo en una recomendación de compra por cultivo.

En números, integramos tres fuentes: los datos oficiales de rendimiento y pesticidas de FAOSTAT, el clima obtenido en vivo desde la API pública del Banco Mundial y un registro interno de compras (anonimizado). El resultado es un modelo dimensional en estrella con 34,113 observaciones limpias de 183 países, entre 1990 y 2023. De los tres algoritmos que probamos, el mejor fue Random Forest, con un R^2 de 0.960 y un error de 1.638 ton/ha sobre datos que no vio en el entrenamiento. Sobre esa predicción, la regla de compra sugiere aumentar el volumen en 5 cultivos (maíz, trigo, yuca, papa, arroz en cáscara), mantenerlo en 2 y reducirlo en 2 para el ciclo 2024.

Fase 1. Definición del Negocio y Entendimiento del Problema

1.1 Contexto del Negocio

AgroComercial del Litoral S.A. es una empresa simulada que usamos como caso de estudio. Funciona como intermediaria en la cadena agrícola: le compra la cosecha al productor, la almacena y la revende a industrias procesadoras, supermercados y mercados de exportación. Su margen sale de comprar el volumen adecuado, a buen precio y en el momento oportuno. El problema es que la materia prima que maneja depende de algo que la empresa no controla. El rendimiento de un cultivo cambia con el clima y con el manejo (riego, pesticidas), y eso hace que la oferta disponible varíe bastante de una temporada a otra.

1.2 Planteamiento del Problema (Cultura Data-Driven)

Hoy las compras se deciden de forma reactiva. El jefe de compras se guía por su experiencia y por lo que pasó la temporada anterior, sin ninguna estimación de cuánto van a rendir los cultivos con el clima que se espera. Ese es el dolor del negocio: no poder anticipar el rendimiento por país o región y temporada. Y cuando no se puede anticipar, aparecen dos situaciones que cuestan dinero:

- Sobrestock: comprar más de lo que el mercado alcanza a absorber. El producto se almacena de más, se deteriora y termina en pérdida. En el registro interno la merma promedio por orden es de 5.5 % (dato del escenario simulado).
- Quiebre de stock: quedarse corto justo cuando hay demanda, con la venta perdida y el riesgo de perder también al cliente.

Pasar a una cultura data-driven significa, en la práctica, dejar de decidir por corazonada y empezar a decidir con evidencia: usar el histórico de rendimiento, clima y pesticidas para estimar el rendimiento esperado y planificar las compras a partir de esa estimación. Que el riesgo existe no es una opinión, se puede medir: la variabilidad interanual del rendimiento en Ecuador tiene un coeficiente de variación de 31.2 %, calculado directamente sobre los datos.

1.3 Objetivos de Analítica (los 4 pilares)

Definimos el alcance separando las cuatro preguntas que la analítica puede responder. Cada pilar tiene un objetivo concreto dentro de este proyecto:

Pilar	Pregunta	Qué hacemos en este proyecto
Descriptiva	¿Qué ha pasado?	Caracterizar el rendimiento histórico por cultivo, país y año, y ver qué cultivos y zonas rinden más y cómo se han movido el clima y los pesticidas.
Diagnóstica	¿Por qué pasó?	Estudiar la relación entre el rendimiento y sus factores

		(lluvia, temperatura, pesticidas), cuidando de no confundir correlación con causalidad.
Predictiva	¿Qué pasará?	Estimar el rendimiento (ton/ha) esperado para un cultivo según las condiciones de clima y manejo, con modelos de regresión.
Prescriptiva	¿Qué conviene hacer?	Recomendar cuánto comprar y qué cultivos priorizar según el rendimiento predicho, con una regla de decisión que reduzca el sobrestock y el quiebre.

1.4 Fuentes de Datos y Ética Inicial

Trabajamos con tres orígenes de datos, uno de ellos una API pública, tal como pedía la consigna:

Tipo	Fuente	Contenido
Dataset (CSV)	FAOSTAT — descarga oficial (bulks-faostat.fao.org, dominios QCL y RP)	Rendimiento (kg/ha) y pesticidas (t) por país, cultivo y año: 34,113 filas, 183 países, 10 cultivos, 1990-2023. Reemplaza al dataset de Kaggle que se había propuesto en la Fase 1, que solo llegaba hasta 2013.
API pública	Banco Mundial: Climate Change Knowledge Portal (cckpapi.worldbank.org) y World Bank Open Data (api.worldbank.org/v2)	Clima oficial por país y año, extraído en vivo: temperatura media (°C) y precipitación anual (mm) de la serie CRU TS 4.08 hasta 2023, más algunos indicadores agrícolas de referencia para Ecuador y cuatro países vecinos.
Excel interno (simulado)	Registro de compras de la empresa	1,527 órdenes históricas con volúmenes, precios de compra y de reventa, canal, región y merma.

Sobre gobernanza y ética (privacidad desde el diseño):



- Los datos de rendimiento y clima vienen agregados por país, así que no contienen datos personales. En el Excel de compras los proveedores aparecen solo con un código anónimo (PROV-001, PROV-002, y así), sin nombres, RUC, teléfonos ni ubicaciones exactas.
- Cada fuente y cada transformación queda registrada en el pipeline y en un reporte de calidad que se genera automáticamente (lo detallamos en la Fase 2), de modo que el origen de un número siempre se puede rastrear.
- El modelo se pensó como apoyo a la decisión, no como reemplazo del jefe de compras. Por eso las predicciones siempre se comunican junto con su margen de error.
- Somos conscientes de que el histórico sobrerrepresenta a ciertos países y cultivos. Ese sesgo lo medimos con números en la Fase 4.2 en lugar de darlo por descontado.

Fase 2. Ingeniería de Datos y Modelado Multidimensional

2.1 Modelado Multidimensional (Esquema Estrella)

Diseñamos un esquema en estrella con dos tablas de hechos y cuatro dimensiones que ambas comparten (dimensiones conformadas). Optamos por estrella y no por copo de nieve porque nos interesaba que las consultas en Power BI fueran simples y con pocos joins. Las dimensiones son chicas, así que normalizarlas más no ahorraría casi nada y sí complicaría el modelo.

Tablas de hechos:

- fact_rendimiento (34,113 filas). El grano es país por cultivo por año. Métricas: rendimiento_ton_ha, precipitacion_mm, pesticidas_ton y temperatura_media_c.
- fact_compras (1,527 filas). El grano es la orden de compra. Métricas: volumen_comprado_ton, precio_compra_usd_ton, precio_reventa_usd_ton, costo_total_usd, ingreso_reventa_usd, margen_bruto_usd y merma_pct.

Tablas de dimensiones:

- dim_tiempo (34 filas): id_tiempo, anio, decada, periodo.
- dim_geografia (183 filas): id_geografia, pais, region_comercial (Ecuador, Latinoamérica de referencia o resto del mundo).
- dim_cultivo (10 filas): id_cultivo, cultivo (nombre FAO en inglés), cultivo_es y categoria (cereal, tubérculo, oleaginosa o musácea).
- dim_proveedor (40 filas): id_proveedor, codigo_proveedor (anónimo) y region_origen (Costa, Sierra o Amazonía).

2.2 Pipeline de Integración (ETL)

El pipeline está hecho en Python (pandas y requests) y se divide en cuatro scripts que se pueden volver a correr sin problema. extraer_datos_actualizados.py une el bulk oficial de FAOSTAT con el clima de la API del Banco Mundial (guardamos una copia en caché local y reintentamos si la API falla por un momento). extract_api.py trae indicadores de referencia del Banco Mundial. generar_compras_internas.py arma la fuente interna simulada, ya sin datos personales desde el origen. Y transform_load.py se encarga de la limpieza, el tipado, la validación y la carga del esquema estrella. Cada corrida deja un reporte de calidad en JSON con lo que se hizo y su efecto.

Calidad de datos (valores de la última corrida):

- Integración por clave país-año. Homologamos los países a códigos ISO3 (y dejamos fuera a propósito los agregados regionales de FAOSTAT como 'Americas' o 'World'), y solo nos quedamos con las combinaciones país-cultivo-año que tienen las cuatro métricas completas.
- Duplicados exactos eliminados: 0 filas en la corrida final.

- Tipado explícito: las métricas se convierten a numérico controlando los errores, y el año queda como entero.
- Nulos: en las métricas críticas de negocio optamos por descartar la fila en lugar de imputar, para no inventar rendimientos que no existieron.
- Rangos físicos: rendimiento mayor que 0, temperatura entre -10 y 45 °C, lluvia entre 0 y 12.000 mm, y pesticidas mayor o igual que 0.
- Consistencia referencial: una verificación automática (assert) confirma que toda clave foránea de los hechos exista en su dimensión.
- Conversión de unidades a la unidad de negocio: de kg/ha a ton/ha.

2.3 Cumplimiento Normativo

Nos alineamos con la LOPDP (Ley Orgánica de Protección de Datos Personales del Ecuador) y con el principio de privacidad desde el diseño. En concreto: las fuentes públicas de la FAO y el Banco Mundial solo traen agregados por país, sin ningún dato personal; la fuente interna se genera anonimizada desde el inicio, con los proveedores existiendo únicamente como códigos, así que en ninguna etapa el pipeline llega a manejar PII; además, el pipeline incluye una verificación que detiene la carga si encuentra columnas de datos personales (nombre, cédula, RUC, teléfono, dirección o correo) en la fuente interna; y toda la trazabilidad de las transformaciones queda guardada en `reporte_calidad.json` en cada corrida.

Fase 3. Analítica Descriptiva, Diagnóstica y Visualización

3.1 Análisis Exploratorio de Datos (EDA)

Para entender las variables clave calculamos medidas de tendencia central (media y mediana) y de dispersión (desviación estándar, rango intercuartílico y coeficiente de variación), y les sumamos la asimetría y la curtosis para ver la forma de cada distribución:

Variable	Media	Mediana	Desv. est.	RIQ	CV %	Asimetría
Rendimiento (ton/ha)	7.267	4.174	8.135	7.971	111.9	2.269
Precipitación anual (mm)	1263.259	1156.4	794.432	1129.8	62.9	0.672
Temperatura media (°C)	20.765	23.77	7.151	9.74	34.4	-1.145
Pesticidas (ton)	18766.508	1742.0	61024.989	9511.0	325.2	6.243

Lo que se ve en la tabla es que en todas las variables la media queda por encima de la mediana y la asimetría es positiva, es decir, las distribuciones tienen cola hacia la derecha: hay pocos casos con valores muy altos que estiran el promedio. El rendimiento global promedia 7.27 ton/ha, pero la mitad de las observaciones está por debajo de 4.17 ton/ha. Los pesticidas son la variable más sesgada, porque unos pocos países concentran casi todo el consumo. Como los datos no son normales, más adelante usamos también la correlación de Spearman y modelos basados en árboles, que aguantan mejor este tipo de colas largas.

Distribuciones de variables clave (todas las geografías)




Figura 1. Distribuciones de las variables clave, con la media (rojo) y la mediana (café).




Figura 2. Rendimiento por cultivo en Ecuador (1990-2023) y evolución de los cuatro cultivos líderes.

Correlación frente a causalidad. La matriz de correlaciones muestra relaciones globales débiles entre el rendimiento y cada factor por separado (lluvia $r = -0.003$, temperatura $r = -0.103$, pesticidas $r = 0.093$). Esto no quiere decir que el clima no importe. Lo que ocurre es que su efecto depende del cultivo y del país, así que al mezclarlo todo la relación global se diluye. El caso de los pesticidas es un buen ejemplo de por qué correlación no es causalidad: los países que más pesticidas usan tienden a rendir más, pero el pesticida es sobre todo una señal de agricultura tecnificada (riego, semillas mejoradas, fertilización), y es esa tecnificación la que

sube el rendimiento, no el pesticida por sí solo. Por eso el análisis diagnóstico se apoya además en el estudio por cultivo y en la importancia de variables del modelo (Fase 4).




Figura 3. Correlación de Pearson y de Spearman entre el rendimiento y sus factores.




Figura 4. Dispersión del rendimiento frente a lluvia, temperatura y pesticidas.

3.2 Diseño de Indicadores (KPIs)

KPI	Valor actual	Pilar al que responde
Rendimiento promedio Ecuador (ton/ha, últimos 5 años)	4.61	Descriptivo — nivel base de oferta esperada
Coeficiente de variación interanual del rendimiento (%)	31.2	Diagnóstico — cuantifica el riesgo de oferta
Margen bruto de reventa (%)	21.4	Descriptivo — salud económica del negocio
Merma promedio por orden de compra (%)	5.5	Diagnóstico — pérdidas por deterioro/sobrestock
Concentración del volumen en top 3 cultivos (%)	62.9	Prescriptivo — riesgo de portafolio de compras

Los cinco KPIs cubren los cuatro pilares que definimos en la Fase 1.3: el nivel de oferta que se espera (KPI 1), el riesgo de esa oferta (KPI 2), la rentabilidad del negocio (KPI 3), las pérdidas operativas (KPI 4) y el riesgo del portafolio de compras (KPI 5). Todos salen directamente del esquema estrella y están implementados como medidas DAX en Power BI.




Figura 5. Margen bruto anual de reventa y volumen histórico comprado por cultivo (fuente interna).

3.3 Dashboard Estratégico y Storytelling

El dashboard lo construimos en Power BI sobre el esquema estrella (en la carpeta powerbi/ está la guía completa de armado, las medidas DAX y el tema de color). Además preparamos una versión interactiva en Streamlit para usar durante la defensa. La narrativa sigue el orden en que decidiría el comité: primero un resumen ejecutivo con los cinco KPIs, luego el diagnóstico de los factores, y al final la predicción con el plan de compras.

Por qué el diseño visual es así:

- Percepción visual. Ubicamos los KPIs en la franja superior, que es por donde entra la mirada, y ordenamos la página en una lectura tipo Z. Agrupamos por proximidad los indicadores relacionados y usamos el mismo color para el mismo cultivo entre gráficos, para que el ojo los vincule solo.
- Comparaciones con posición y longitud (líneas y barras), que son las que el ojo lee con más precisión. Evitamos gráficos de pastel y de área, donde los ángulos se estiman peor.
- Color con significado. El verde #2E7D32 es el color corporativo (agro, crecimiento, decisión positiva) y el rojo #C62828 lo reservamos solo para las alertas de reducir compra, para que con verlo ya se entienda que hay riesgo. El ámbar es para lo neutro. No pasamos de cuatro colores con significado por página.
- Tipografía en una sola familia sans-serif (Segoe UI), con la jerarquía dada por el tamaño y el peso, y cifras grandes en las tarjetas de KPI para que se lean de lejos en la defensa.

Fase 4. Analítica Predictiva y Gobernanza de IA

4.1 Modelado Predictivo (Machine Learning)

Lo planteamos como un problema de regresión: estimar el rendimiento (ton/ha) a partir de seis variables predictoras, que son el año, la lluvia anual, los pesticidas, la temperatura media, el país y el tipo de cultivo. El preprocesamiento escala las variables numéricas y aplica one-hot encoding a las categóricas, todo dentro de un Pipeline de scikit-learn (así el mismo objeto sirve para entrenar y para predecir después). Partimos los datos 80/20 (27,290 filas de entrenamiento y 6,823 de prueba) y usamos validación cruzada de 5 particiones sobre el conjunto de entrenamiento.

Modelo	RMSE (ton/ha)	MAE (ton/ha)	R ² (prueba)	R ² validación cruzada (5)
Regresión Lineal	4.613	3.117	0.6792	0.6676 ± 0.0067
Árbol de Decisión	3.045	1.804	0.8602	0.8342 ± 0.0076
Random Forest	1.638	0.811	0.9595	0.9384 ± 0.0036

Para evaluar usamos las métricas que corresponden a un problema de regresión: RMSE (el error en las mismas unidades del negocio, ton/ha, que además castiga los errores grandes), MAE (el error típico) y R² (la parte de la variabilidad que el modelo logra explicar). El ganador fue Random Forest: explica el 96.0 % de la variabilidad del rendimiento, con un RMSE de 1.638 ton/ha y un MAE de 0.811 ton/ha. La regresión lineal es más fácil de interpretar pero se queda en un R² de 0.68, porque la relación entre el clima y el rendimiento no es lineal y depende de interacciones (cultivo, país y clima juntos) que los árboles capturan mejor. Que el R² de prueba y el de validación cruzada estén tan cerca (0.960 frente a 0.938) nos dice que no hay sobreajuste importante.




Figura 6. Comparación de los modelos: R² y RMSE en el conjunto de prueba.




Figura 7. Rendimiento predicho frente al real del modelo ganador (la línea marca la predicción perfecta).

Pilar prescriptivo: la regla de decisión sobre la predicción.

Para cada cultivo del portafolio en Ecuador predecimos el rendimiento del siguiente ciclo bajo un escenario climático base (el promedio de los últimos tres años) y calculamos un índice de oferta, que es el rendimiento predicho dividido entre el promedio histórico. La regla es sencilla: si el índice es mayor o igual a 1,05 conviene aumentar la compra un 15 %, porque va a haber oferta abundante y los precios tienden a bajar; si queda entre 0,95 y 1,05 se mantiene; y si es menor que 0,95 se reduce un 15 % y se aseguran contratos por adelantado, porque el riesgo es de escasez y sobreprecio.

Cultivo	Predicho (ton/ha)	Histórico (ton/ha)	Índice	Decisión
Maíz	4.42	2.34	1.891	AUMENTAR compra
Trigo	1.51	0.94	1.613	AUMENTAR compra
Yuca	6.37	4.45	1.43	AUMENTAR compra
Papa	13.27	9.33	1.422	AUMENTAR compra
Arroz en cáscara	3.98	3.59	1.109	AUMENTAR

				compra
Sorgo	1.69	1.61	1.046	MANTENER volumen
Plátano y otros	6.97	7.06	0.988	MANTENER volumen
Camote	2.32	2.56	0.907	REDUCIR compra
Soya	1.36	1.55	0.874	REDUCIR compra

4.2 Ética de la IA y Gobernanza de Datos

Sesgos algorítmicos: nuestro análisis crítico.

- Sesgo de representación. El dataset tiene muchas más filas de países con estadísticas completas (Cameroon: 340 filas) que de otros con series cortas (Seychelles: 34). Con los cultivos pasa parecido: los de alcance global (Maize: 5,120 filas) pesan más que los más regionales (Plantains and others: 1,530). Ecuador tiene 306 filas, una representación intermedia que nos parece razonable.
- El riesgo de esto es que el modelo aprenda mejor a los grupos dominantes y prediga peor, es decir, 'discrimine' en términos estadísticos, a los países o cultivos con pocos datos.
- Para no quedarnos en la sospecha lo medimos. El RMSE para Ecuador es de 0.727 ton/ha, mejor que el promedio global de 1.638, así que el sesgo no perjudica a nuestro mercado objetivo. Por cultivo el error va de 0.344 (Soybeans) a 2.863 (Potatoes); revisándolo, ese error se explica más por la escala y la varianza del rendimiento de cada cultivo (la papa va de 5 a 50 ton/ha según el país, mientras que la soya se mueve en un rango estrecho) que por la representación. Aun así, las recomendaciones de los cultivos con más error se entregan al negocio con una advertencia de mayor incertidumbre.
- Sesgo temporal. El histórico llega hasta 2023, porque FAOSTAT publica con uno o dos años de rezago. El pipeline automatizado permite reentrenar en cuanto salga la actualización oficial, antes de cada campaña.

IA explicable (XAI):

Para que el comité pueda confiar en el modelo calculamos la importancia de cada variable por permutación, que mide cuánto baja el R^2 cuando se desordena esa variable. El resultado tiene sentido para el negocio: el tipo de cultivo es de lejos lo que más pesa (una papa rinde en toneladas muchísimo más que un trigo), seguido del país, que funciona como resumen del suelo, la tecnología y las variedades de cada lugar. Entre los factores que sí se pueden monitorear o ajustar, los pesticidas (0.27), la temperatura (0.21) y la lluvia (0.12) tienen un peso parecido. Dicho de forma simple: el modelo primero identifica el cultivo y el país, y luego ajusta la estimación con el clima y el manejo del año. Es parecido a cómo razonaría un agrónomo con experiencia, solo que con la memoria de 34,113 cosechas encima.




Figura 8. Importancia de variables por permutación (XAI) del modelo ganador.

Gobernanza del modelo. El pipeline completo (preprocesamiento y modelo) se guarda como un solo archivo versionado (modelo_rendimiento.joblib); las predicciones siempre se comunican con su margen de error (± 1.638 ton/ha); y la decisión final de compra la sigue tomando el comité, con el modelo como apoyo. Esta supervisión humana la dejamos definida desde la Fase 1.



Conclusiones

- Cerramos el ciclo analítico completo: integramos tres fuentes (una de ellas una API pública), documentamos un esquema estrella, hicimos un EDA con base estadística, definimos cinco KPIs, entrenamos un modelo predictivo con R^2 de 0.960 y armamos una regla prescriptiva que convierte esa predicción en decisiones de compra concretas.
- El valor para el negocio es directo: anticipar la oferta permite comprar más cuando se espera abundancia (y mejores precios) y asegurar contratos cuando se espera escasez, lo que reduce a la vez el sobrestock y el quiebre de stock.
- También somos honestos con las limitaciones: el error es mayor en los cultivos con pocos datos, FAOSTAT publica con rezago (el histórico llega hasta 2023) y las compras internas son simuladas. Cada una de esas limitaciones tiene su mitigación documentada.
- Como trabajo futuro queda reentrenar el modelo con cada actualización de FAOSTAT, sumar precios de mercado reales para pasar de una regla de decisión a una optimización de margen, y bajar el análisis a nivel de provincia cuando existan datos subnacionales.